

Обучение представлению групп точек данных

Каримов П.Д.
Научный руководитель: Исаченко Р.В.

December 2023

Аннотация

В данной статье рассматривается задача сопоставления информативных векторных представлений групп данных. Исходный датасет состоит из пар (x_i, y_i) , где $x_i \in X$ и $y_i \in \{1, \dots, K\}$. Для достижения данной цели, мы рассматриваем оптимально обученные представления, которые позволяют преобразовать группы $G_{j,k}$ в векторные представления $f_\theta(G_{j,k})$.

1 Постановка задачи

Пусть дан датасет $\mathfrak{G} = \{(x_i, y_i)\}_{i=1}^n$, $x_i \in X$, $y_i \in \{1, \dots, K\}$. Составим из этих точек данных множества:

$$G_{j,k} = \{x_i | (x_i, y_i) \in \mathfrak{G} \wedge y_i = k \forall i\} : \forall j_1, j_2 G_{j_1,k} \cap G_{j_2,k} = \emptyset$$

Наша задача состоит в том, чтобы сопоставить каждой группе $G_{j,k}$ эмбединг $f_\theta(G_{j,k})$, представляющий собой информативное векторное представление $G_{j,k}$. Определение "информативного" в задаче обучения представлениям обычно формулируется под конкретную задачу (Representation Learning: A Review and New Perspectives), обычно полагают, что в рамках такого представления "близкие" в каком-то смысле объекты находятся в пространстве представлений близко, а "далёкие" далеко.

2 Существующие работы

Данная задача обычно применяется к задаче объектного различения (instance discrimination) для учёта групповой информации между объектами для улучшения качества модели. Ниже представлены общие описания рассмотренных статей.

2.1 Unsupervised Visual Representation Learning by Synchronous Momentum Grouping

Обычно это делается минимизацией лосса, который учитывает взаимодействия между айтемами:

$$L_i = -\log \frac{\exp(\text{sim}(f_\theta(x_i^a), f_\theta(x_i^b)))}{\sum_j \exp(\text{sim}(f_\theta(x_i^a), f_\theta(x_j)))}$$

Можно попробовать обобщить этот лосс до групп, чтобы получить фичи для групп:

$$L_i = -\log \frac{\exp(\text{sim}(c_i^a, c_i^b))}{\sum_j \exp(\text{sim}(c_i^a, g_j))}$$

Но если пытаться делать так - некоторые айтемы могут быть близки одновременно нескольким группам.

Если мы хотим, чтобы группы были таки существенно разные (с точки зрения айтемов, которые хочется этим группам соотнести) - стоит брать group-item лосс:

$$L_i = -\log \frac{\exp(\text{sim}(f_\theta(x_i^a), c_i^b))}{\sum_j \exp(\text{sim}(f_\theta(x_i^a), g_j))}$$

Здесь x_i^a - характеристики a -ого объекта, принадлежащего i -ому классу; c_i^b - групповая характеристика b -го объекта.

Таким образом, мы пытаемся приблизить семплы группы к самой группе и отдалить эти семплы от других групп.

Группы инициализируются, например, каким-нибудь алгоритмом кластеризации. Обновляются группы так:

$$c_i = \arg \min_{g_k} \text{sim}(f_\theta(x_i), g_k) \\ g_k \leftarrow \beta g_k + (1 - \beta) \text{mean}_{c_t = g_k} f_\theta(x_t)$$

Такой способ позволяет через эмбеда группы пропускать градиенты, и этим отличается от аналогов, которые приводятся в статье.

Поскольку составленные таким образом группы могут коллапсировать из-за того, что на каждом шаге мы движемся по батчу - авторы предлагают периодически перегруппировывать центроиды.

2.2 GroupFace: Learning Latent Groups and Constructing Group-based Representations for Face Recognition

В этой статье авторы предлагают к эмбедам инстансным добавлять прямо групповые фичи (явно), представляя специфическую архитектуру сети.

В качестве лосса берут сумму классификационного (CE-лосс) и репрезентационного (ArcFace-лосс) с какими-то весами.

Специфичным образом определяется принадлежность к группе, пытаясь адресовать неравномерность распределения по группам - не

$$\arg \max_k p(G_k|x)$$

, а

$$\arg \max_k \frac{1}{K} (p(G_k|x) - \mathbb{E}[p(G_k|x)]) + \frac{1}{K}$$

Перескоринг интуитивно обосновывается тем, что матожидание этой величины равно $\frac{1}{K}$.

2.3 The Group Loss for Deep Metric Learning

В этой статье авторы ставят в противовес классическому выбору лосса в Representation learning a.k.a. Contrastive/Triplet loss свой лосс, который каждому айтому в батче ставит группу. Делают они это вытаскиванием фичей из нейронки, подачей софтмакс-вероятностей как начальному приближению их классов и запускают некоторый итерационный процесс. По окончании берут CE-лосс и бегут backprop-ом.

3 Результаты

В рамках представленной задачи можно посмотреть в сторону того, что будет, если мы оптимально потренируем представления на уровне айтемов, например:

Теорема 1 Пусть мы имеем оптимально обученную функцию представления объектов $f_\theta(x)$ с точки зрения Triplet loss-a, то есть для любого айтема x_a , его позитива x_p и негатива x_n верно, что

$$\exists m : ||f_\theta(x_a) - f_\theta(x_p)|| - ||f_\theta(x_a) - f_\theta(x_n)|| \leq m \quad \forall(a, p, n)$$

Рассмотрим группы $G_{j_1, k_1}, G_{j_2, k_1}, G_{p_1, k_2}$, в качестве эмбединга группы возьмём $f_\theta(G_{j, k}) = \frac{1}{|G_{j, k}|} \sum_{x \in G_{j, k}} f_\theta(x)$. Тогда

$$f_\theta(G_{j_1, k_1}) - f_\theta(G_{j_2, k_1}) \leq 2 \max\{m, \max_{s_1 \in G_{j_1, k_1}, s_2 \in G_{p_1, k_2}} ||s_1 - s_2||\}$$

Таким образом, выбор представления группы как среднего арифметического поайтежных эмбедов в случае, если $m < 0$, является в какой-то степени оправданным. Отметим, однако, что в теореме ничего не упоминается про расстояние с центроидом отрицательного примера ещё, в этом направлении ещё предстоят некоторые исследования.

Список литературы

- [Bengio et al.(2012)Bengio, Courville, and Vincent] Yoshua Bengio, Aaron C. Courville, and Pascal Vincent. Representation learning: A review and new perspectives. volume 35, pages 1798–1828, 2012. URL <https://api.semanticscholar.org/CorpusID:393948>.
- [Pang et al.(2022)Pang, Zhang, Li, Cai, and Lu] Bo Pang, Yifan Zhang, Yaoyi Li, Jia Cai, and Cewu Lu. Unsupervised visual representation learning by synchronous momentum grouping. In *European Conference on Computer Vision*, 2022. URL <https://api.semanticscholar.org/CorpusID:250490993>.
- [Kim et al.(2020)Kim, Park, Roh, and Shin] Yonghyun Kim, Wonpyo Park, Myung-Cheol Roh, and Jongju Shin. Groupface: Learning latent groups and constructing group-based representations for face recognition. pages 5620–5629, 06 2020. doi:10.1109/CVPR42600.2020.00566.
- [Elezi et al.(2019)Elezi, Vascon, Torcinovich, Pelillo, and Leal-Taixé] Ismail Elezi, Sebastiano Vascon, Alessandro Torcinovich, Marcello Pelillo, and Laura Leal-Taixé. The group loss for deep metric learning. In *European Conference on Computer Vision*, 2019. URL <https://api.semanticscholar.org/CorpusID:208527171>.